



Линейная регрессия



Логистическая регрессия



Форма датасета

n	Площадь квартиры (x)	Реальная стоимость аренды (y_true)	Предсказанная стоимость аренды (y_pred)
1	50	60 000	58 654
2	28	25 000	23 634
...
N	35	28 000	31 634

n	Количество кликов (x)	Покупка (t)	Предсказанная вероятность (p)
1	50	1	0.85
2	5	0	0.28
...
N	67	1	0.64

Функция для минимизации

$$Loss(w_0, w_1) = \sum_{i=1}^N (y_{true\ i} - y_{pred\ i})^2$$

$$y_{pred\ i} = w_0 + w_1 \cdot x$$

Линейная модель предсказывает целевую переменную

Подбор коэффициентов осуществляется методом градиентного спуска.


$$Loss(w_0, w_1) = - \sum_{i=1}^N (t_i \cdot \ln(p_i) + (1 - t_i) \cdot \ln(1 - p_i))$$

$$\ln\left(\frac{p_i}{1 - p_i}\right) = w_0 + w_1 \cdot x$$

Линейная модель предсказывает логарифм шансов быть объектом класса 1

Градиентный спуск - численный метод нахождения минимума функции

$$loss(w_0, w_1(0))$$



Чтобы лучше понять градиентный спуск, посмотри второе видео в плейлисте, посвященном обучению нейронных сетей, от 3Blue1Brown. Длительность видео 21 минута.



1. Сперва коэффициенты w_0 и w_1 инициализируются случайным образом:
 $w_0 = w_0(0)$ $w_1 = w_1(0)$
2. Считается тангенс наклона касательной вдоль направлений w_0 и w_1
3. Происходит обновление w_0 и w_1

$$w_0(1) = w_0(0) - \alpha \cdot \left. \frac{\partial loss(w_0, w_1)}{\partial w_0} \right|_{w_0(0), w_1(0)}$$

learning rate
(коэффициент скорости обучения)

$$w_1(1) = w_1(0) - \alpha \cdot \left. \frac{\partial loss(w_0, w_1)}{\partial w_1} \right|_{w_0(0), w_1(0)}$$

Метрики регрессии

Средняя абсолютная ошибка

$$MAE = \sum_{i=1}^N |y_{true\ i} - y_{pred\ i}|$$

Коэффициент множественной корреляции

$$R = corr(y_{true}, y_{pred})$$

Коэффициент детерминации - квадрат коэффициента множественной корреляции.
Можно показать, что:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_{true\ i} - y_{pred\ i})^2}{\sum_{i=1}^N (y_{true\ i} - \bar{y})^2}$$

Показывает, насколько модель работает лучше, чем предсказание среднего.

Если для каждого примера предсказывать среднее, то $R^2 = 0$.
Если делать хорошие предсказания, то $R^2 \rightarrow 1$.

Посмотри это 20-минутное видео от 3Blue1Brown, чтобы лучше понять метрики классификации.




Метрики классификации

ROC AUC показывает вероятность того, что если взять один объект класса 0 и один объект класса 1, то score на классе 1 будет больше score на классе 0.
ROC AUC Random = 0.5
ROC AUC Ideal = 1.0

Метрики для меток.

Пусть при определённом пороге принятия решения мы получили картинку:



Фундаментальные метрики классификатора

$$TPR = \frac{TP}{TP + FN} \quad (Sensitivity \text{ or } Recall)$$

$$TNR = \frac{TN}{TN + FP} \quad (Specificity)$$

Любые другие метрики классификации выражаются через TPR, TNR и Prevalence


$$Precision = \frac{TP}{TP + FP} \approx \frac{\text{Prevalence}}{1 - TNR}$$

↓
Распространённость целевого класса

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Мульти-класс классификация


Логистическая регрессия (на 2 класса)



$$z = w_0 + w_1 \cdot x$$


$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Мульти-класс логистическая регрессия на 2 класса



$$SM(z_i) = \frac{e^{z_i}}{e^{z_1} + e^{z_2}}$$

Мульти-класс логистическая регрессия на 3 класса



! Можно показать, что эти 2 подхода идентичны !